异构交流变压器振动异常检测：基于Zerone机理嵌入与CWT-ResNet-VAE的深度生成框架研究报告

1. 绪论与背景综述

1.1 工业背景与问题陈述

在现代电力系统中，电力变压器作为核心枢纽设备，其运行可靠性直接关系到电网的安全稳定。随着电网规模的扩大和设备役龄的增长，变压器内部绕组变形、铁芯松动、分接开关接触不良等机械故障的早期预警显得尤为迫切。振动监测作为一种非侵入式的状态感知手段，能够捕捉由磁致伸缩力和洛伦兹力引发的微小机械变化，已成为变压器故障诊断的重要技术路径。

然而，在实际工业部署中，振动监测面临着极其严峻的“异构性”挑战。这种异构性主要体现在以下三个维度：

1. **设备型号差异**：电网中同时运行着不同厂家、不同电压等级（如110kV, 220kV, 500kV）、不同冷却方式（ONAN, ONAF, ODWF）的变压器。不同容量和结构的变压器，其基准振动幅值和频谱特征存在天然差异。
2. **传感器布置差异**：受限于现场安装条件，加速度传感器可能安装在油箱壁的不同位置（上部、中部、下部）、加强筋上或冷却器基座上。即使是同一台设备，不同测点的传递函数也截然不同。
3. **运行工况波动**：负载电流的变化会直接改变洛伦兹力的大小，导致振动信号随负荷波动而呈现非平稳特性。

传统的基于单一阈值或浅层机器学习的监测方法，在面对这种异构数据时，往往陷入两难境地：若阈值设置过宽，则漏报率高；若阈值过窄，则因设备间的基准差异导致误报频发。此外，变压器作为高可靠性设备，其全生命周期中大部分时间处于健康状态，故障样本极度稀缺，且标签获取成本高昂。这使得依赖海量标注数据的监督学习方法难以落地，必须转向**无监督学习**范式。

1.2 研究目标与技术路线

本报告旨在针对上述挑战，制定一套基于无监督学习的完整代码实现方案。该方案的核心思想是：**不直接对抗异构性，而是通过编码将异构性作为上下文信息融入模型**。

我们将深度融合**Zerone代码逻辑**（特征工程+机理嵌入）[1]与**信号转图像+变分自编码器（VAE）**[1]的先进理念，构建一个名为 **Hetero-CWT-Zerone-VAE** 的深度生成模型框架。

本报告将重点解决以下三个核心问题：

1. **Zerone核心判别逻辑的深度解析与迁移**：分析Zerone如何通过将统计特征、频域特征与离散的工况信息（如型号、位置）统一编码为二维图像，从而解决异构数据的特征对齐问题。
2. **最佳VAE模型架构的确定**：论证为何连续小波变换（CWT）配合残差网络（ResNet）的VAE架构最适合处理包含丰富瞬态与稳态成分的变压器振动数据，并探讨空间隐空间（Spatial Latent Space）相对于稠密隐空间（Dense Latent Space）的优势。
3. **无监督训练与伪标签扩充流程设计**：设计一套从纯无监督预训练开始，通过重构误差分布分析生成高置信度伪标签，进而迭代优化模型的半监督闭环流程。

---

2. 变压器振动信号的物理机理与数据异构性分析

2.1 振动产生的物理机制

为了设计有效的特征提取逻辑（对应Zerone中的特征部分），必须首先从物理层面理解变压器振动的来源。变压器振动主要由两个物理过程主导：

1. 铁芯的磁致伸缩（Magnetostriction）：
   铁芯硅钢片在交变磁场的作用下发生微小的尺寸伸缩变化。由于磁致伸缩率与磁通密度的平方成正比，且不区分磁通方向，因此其基频为电源频率的2倍（即100Hz或120Hz）。铁芯振动具有明显的非线性，会产生丰富的高次谐波（$2kf$）。当铁芯夹件松动时，100Hz及其谐波分量的幅值会显著增加，且可能出现非线性的调制边带。
2. 绕组的洛伦兹力（Lorentz Forces）：
   绕组线圈中流过的负载电流与漏磁场相互作用产生电动力。该力的大小与电流的平方成正比，频率同样为电源频率的2倍。这解释了为何振动信号会随负载（运行工况）剧烈波动。绕组变形或压紧力不足会导致绕组固有频率变化，进而引发共振或幅值异常。

异构性的物理根源：
不同型号变压器的铁芯材质、叠片方式、绕组结构不同，导致其磁致伸缩系数和机械传递函数不同。传感器安装位置的不同，意味着振动波从声源（铁芯/绕组）传播到传感器（油箱壁）经过了不同的油层和钢板介质，造成了幅值衰减和相位延迟的巨大差异。

2.2 传统方法的局限性与Zerone逻辑的引入契机

面对异构数据，传统方法通常试图进行“归一化”或“标准化”以消除设备差异。然而，这种做法往往会抹杀掉反映设备健康状态的细微特征。

Zerone逻辑的创新点[1] 在于它反其道而行之：它不是试图消除差异，而是将差异**显式编码**。

- 在Zerone方法中，不仅提取了信号的时域统计特征和频域特征，更重要的是将“工况信息”（如转速、负载、故障类型等文本/类别信息）直接转化为图像的一部分。
- 通过将“设备型号”和“传感器位置”作为上下文（Context）输入给神经网络，网络能够学习到条件概率分布 $P(X_{vibration} | Context)$。
- 这意味着，模型可以学会：“对于A型变压器，0.5g的振动是正常的；但对于B型变压器，0.5g的振动可能意味着异常”。这种上下文感知的建模能力，正是解决变压器异构数据监测难题的钥匙。

---

3. Zerone代码核心判别逻辑深度解析与迁移

Zerone方法[1] 最初是为轴承故障诊断设计的，其核心是将一维信号和文本信息转化为二维图像，以便利用卷积神经网络（CNN）强大的特征提取能力。针对变压器振动数据，我们需要对其逻辑进行深度的解构与适配。

3.1 核心逻辑一：多模态特征的统一网格化映射

Zerone代码最本质的创新在于构建了一个能够容纳不同数据类型的“信息容器”（Image Container）。它打破了时域、频域和元数据（Metadata）之间的壁垒。

3.1.1 特征提取层（Feature Extraction）

Zerone首先定义了一组强机理相关的特征算子。对于变压器振动，我们应沿用并扩展其定义的时域特征集，因为这些特征对冲击和波形畸变高度敏感。

表 3.1：适配变压器的Zerone核心时域特征集

特征编号	特征名称	数学定义	物理意义	变压器异常关联
T1	均值 (Mean)	$\frac{1}{N}\sum x_i$	直流分量偏移	传感器零漂
T2	有效值 (RMS)	$\sqrt{\frac{1}{N}\sum x_i^2}$	振动能量总值	整体松动、过载
T3	方差 (Variance)	$\frac{1}{N}\sum (x_i-\bar{x})^2$	波动程度	负荷波动影响
T4	偏度 (Skewness)	$\frac{1}{N}\sum (\frac{x_i-\bar{x}}{\sigma})^3$	分布不对称性	单向冲击（如放电）
T5	峭度 (Kurtosis)	$\frac{1}{N}\sum (\frac{x_i-\bar{x}}{\sigma})^4$	冲击特性	机械部件松动撞击
T6	裕度指标 (Margin Factor)	X_{max} / X_{rms}^2	波形畸变度	早期磨损
T7	波形因子 (Shape Factor)	$X_{rms} / \bar{	x	}$

T8	脉冲因子 (Impulse Factor)	$X_{max} / \bar{	x	}$

除了时域特征，Zerone还引入了STFT频域特征。针对变压器，我们建议将其替换为**特征频带能量占比**，重点关注基频（100Hz）、二次谐波（200Hz）、三次谐波（300Hz）以及高频段（>1kHz）的能量，因为变压器故障往往体现为特定谐波分量的能量重分布。

3.1.2 上下文嵌入层（Context Embedding）——解决异构性的关键

这是Zerone代码中最具判别力的逻辑。它处理非数值型数据（Categorical Variables）的方法非常巧妙：

1. **离散化映射**：将“设备型号”、“传感器位置”等离散变量映射为唯一的整数ID。
2. **位置编码**：在最终生成的图像矩阵中，预留特定的行或列（通常是顶部或边缘），用于填充这些ID归一化后的数值。
3. **隐式关联**：当CNN卷积核扫过这部分区域时，它实际上是在读取“当前处理的数据属于哪一类设备”。这相当于给模型输入了一个先验（Prior）。

3.2 核心逻辑二：色彩归一化（Color Normalization）与连续性保留

原版Zerone论文[1]提到了“二值化（Binarization）”操作，即将归一化后的特征值按0.5阈值变为0或1。

- **批判性分析**：对于分类任务（[1]中的轴承故障分类），二值化有助于增强鲁棒性，去除噪声。但是，对于我们的**无监督重构任务（VAE）**，二值化是极其有害的。
- **VAE的需求**：VAE通过计算输入与输出的重构误差（MAE/MSE）来判断异常。如果输入被二值化，大量细微的幅值变化信息（例如振动幅值从0.6变为0.8，这可能预示着早期故障）将全部丢失（都为1）。
- **改进方案（Soft-Zerone）**：我们保留Zerone的**色彩归一化（Color Normalization）逻辑，即利用Jet Colormap将数值映射为RGB三通道颜色值，但坚决舍弃二值化步骤**。我们将保留连续的浮点数或的像素值。这样既利用了ResNet对图像纹理的敏感性，又保留了物理量的精度，这是本方案针对VAE架构所做的关键适配。

3.3 核心逻辑三：特征掩码（Feature Masking）数据增强

Zerone代码引入了Feature Masking 1 作为数据增强手段，即随机将图像中的某些特征区域置零。在变压器无监督训练中，这一逻辑具有极高的价值：

- **防止过拟合**：由于正常样本可能存在某种特定的虚假相关性（例如某型号变压器总是伴随着特定的噪声），Masking迫使模型利用剩余特征去推断整体状态，学习到更鲁棒的全局特征分布。
- **模拟传感器失效**：随机Mask掉某些频段或时域指标，可以模拟部分传感器通道失灵或受到瞬时干扰的情况，提高模型在恶劣工况下的泛化能力。

---

4. 最佳VAE模型架构设计：Hetero-CWT-ResNet-VAE

基于对变压器振动信号非平稳特性的理解，以及对[1]中“空间隐空间（Spatial Latent Space）”优势的分析，我们提出一种混合架构。该架构不再使用简单的STFT或原始信号作为输入，而是采用**连续小波变换（CWT）**作为主通道，结合Zerone特征图作为辅助通道。

4.1 为什么选择CWT而非STFT或FSST?

虽然[1]使用了同步挤压变换（FSST）[1]，但在变压器场景下，CWT具有独特优势：

1. **多分辨率特性**：变压器信号同时包含低频的主磁通振动（100Hz）和可能存在的高频局部放电或机械撞击信号（数kHz）。STFT的窗口大小固定，无法同时兼顾低频的频率分辨率和高频的时间分辨率。CWT通过伸缩平移小波基，在低频处具备高频率分辨率（能区分95Hz和100Hz），在高频处具备高时间分辨率（能定位瞬态冲击），完美契合变压器信号特性。
2. **图像纹理丰富**：CWT生成的时频图（Scalogram）具有更平滑且丰富的纹理结构，非常适合卷积神经网络（CNN）提取空间特征。

4.2 模型整体架构定义

我们将构建一个**三通道复合输入**的VAE模型。

4.2.1 输入层设计（The Composite Input）

输入张量维度设计为 $(B, 3, 256, 256)$，其中 B 为Batch Size。三个通道分别承载不同的信息流：

- **通道 1 (R通道)：CWT时频图**
  - 内容：原始振动信号经过Morlet小波变换后的模值图。
  - 作用：提供信号最原始、最丰富的动力学信息。
  - 预处理：对数变换增强弱信号可见度，并归一化至。
- **通道 2 (G通道)：Zerone机理特征网格**
  - 内容：将3.1节提取的13个时域特征和5个频带能量特征，归一化后，按Zerone的逻辑平铺填充成 256×256 的网格。
  - 作用：显式地告诉网络物理机理层面的统计规律，引导网络关注重点物理量。
- **通道 3 (B通道)：Zerone上下文网格**
  - 内容：将“设备型号ID”、“传感器位置ID”、“负载率”归一化后平铺。
  - 作用：**解决异构性**。这层信息作为条件约束，迫使Encoder在编码时考虑设备背景。例如，看到通道3是“型号A”，Encoder就会以“型号A”的标准去理解通道1的振动幅值。

4.2.2 编码器（Encoder）与空间隐空间

参考[1]的研究结论，保留空间结构对于图像重构至关重要。因此，我们摒弃传统的全连接层瓶颈（Dense Bottleneck）。

- **骨干网络**：采用ResNet-18（去掉最后的全连接层和平均池化层）。ResNet的残差连接有助于梯度在深层网络中传播，能更好地捕获图像的细粒度纹理。
- **下采样策略**：经过4个ResNet Block后，输入 256×256 被下采样为 8×8 的特征图，通道数扩展为512。
- **变分层（Variational Layer）**：
  - 不进行Flatten操作。
  - 使用两个并行的卷积层（Kernel 1×1），分别将512通道映射为隐空间维度 D_{latent}（例如64通道）。
  - **输出**：均值张量 $\boldsymbol{\mu} \in \mathbb{R}^{B \times 64 \times 8 \times 8}$ 和对数方差张量 $\log\boldsymbol{\sigma}^2 \in \mathbb{R}^{B \times 64 \times 8 \times 8}$。
  - 这种**空间隐空间**（Spatial Latent Space）保留了振动信号在时间轴和频率轴上的拓扑结构，使得重构后的图像边缘更清晰，异常定位更准确[1]。

4.2.3 重参数化与解码器（Decoder）

- 重参数化（Reparameterization Trick）：
  $$ \mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}) $$
  采样得到的 $\mathbf{z}$ 同样保持 $64 \times 8 \times 8$ 的空间结构。
- **解码结构**：
  - 结构与Encoder对称。使用**转置卷积（ConvTranspose2d）**或**上采样+卷积（Upsample + Conv）**进行上采样。
  - 每一层上采样后，接一系列残差块（Residual Blocks）以精修特征。
  - 最后通过一个Sigmoid激活函数层，将输出限制在区间，得到重构图像 $\hat{X}$。

4.3 损失函数设计：平衡重构与分布约束

为了训练该模型，我们需要最小化负的证据下界（ELBO）。损失函数由两部分组成：

1. 重构损失（Reconstruction Loss）：
   通常VAE使用MSE（均方误差），但在图像异常检测中，1指出**L1损失（MAE）**能产生更清晰的图像边缘，且对异常造成的局部大误差更敏感。因此建议采用MAE：

   $$\mathcal{L}_{recon} = \frac{1}{H \times W \times C} \sum_{i,j,k} |X_{i,j,k} - \hat{X}_{i,j,k}|$$
2. KL散度（Kullback-Leibler Divergence）：
   约束隐变量分布接近标准正态分布。对于空间隐空间，KL散度是对每个空间位置求和：

   $$\mathcal{L}_{KL} = -\frac{1}{2} \sum_{spatial} \sum_{channel} (1 + \log\sigma^2 - \mu^2 - \sigma^2)$$
3. β-VAE与周期性退火（Cyclical Annealing）：
   为了防止“KL消失”现象（即Decoder忽略隐变量，退化为自回归模型），需要动态调整KL项的权重 β。建议采用1中提到的周期性退火策略：

   $$\mathcal{L}_{total} = \mathcal{L}_{recon} + \beta(t) \cdot \mathcal{L}_{KL}$$

   其中 $\beta(t)$ 在训练过程中从0逐渐增加到1，并周期性重置。这能让模型先学会“重构”，再学会“规范化”。

---

5. 无监督训练与有标签数据扩充（伪标签）流程详解

针对用户“无监督训练与有标签数据扩充”的需求，我们设计了一个从纯无监督启动，逐步过渡到半监督的闭环迭代流程。这一流程借鉴了[1]中利用VAE重构误差构建健康指标（Health Index）的思路，并引入了置信度阈值机制。

5.1 第一阶段：冷启动——纯无监督预训练

目标：利用海量的无标签历史数据（假设其中绝大多数为健康样本），让模型学习“正常变压器”在不同工况下的振动模式流形（Manifold）。

步骤：

1. **数据清洗**：基于简单的统计规则（如剔除幅值超过物理极限的噪点）清洗数据库。
2. **构建异构数据集**：将所有型号、所有测点的变压器数据混合。
3. **Zerone变换**：按照第3节和4.2.1节的方法，将每一段振动信号转化为三通道复合图像。**关键点**：必须准确填入通道3的上下文信息（型号、位置）。
4. **模型训练**：
   - 输入：复合图像 X。
   - 目标：最小化 $\mathcal{L}_{total}$。
   - 增强：启用Zerone Feature Masking，随机遮挡时频图的某些块，迫使模型学习全局依赖。
5. **基准建立**：训练完成后，将训练集再次输入模型，计算所有样本的重构误差（Reconstruction Error, RE）和KL散度，形成基准分布。

5.2 第二阶段：异常评分与阈值界定

异常评分函数：
综合利用重构质量和隐空间分布距离，定义异常得分 $S(x)$：

$$S(x) = \mathcal{L}_{recon}(x) + \gamma \cdot \mathcal{L}_{KL}(x)$$

其中 γ 为平衡系数。
阈值确定策略：
由于没有故障标签，我们无法通过F1-score确定阈值。采用**极值理论（EVT）**或简单的统计分位数法：

- 对验证集（假设纯健康）的 $S(x)$ 进行直方图统计。
- 设定**健康阈值 $T_{healthy}$**：如95%分位数。得分低于此，大概率为健康。
- 设定**异常阈值 $T_{anomaly}$**：如99.9%分位数或 $Mean + 4\sigma$。得分高于此，极大概率为异常。

5.3 第三阶段：伪标签生成与半监督微调（Self-Training Loop）

这是解决“数据扩充”的核心步骤。通过模型的自我预测，挖掘高置信度样本，逐步扩充有标签数据集。

详细流程图逻辑：

1. 推理与筛选：
   使用当前训练好的VAE模型对未见过的监测数据流进行推理，计算得分 $S(x)$。
2. **三路分流（Triage）**：
   - **高置信度健康（High-Confidence Healthy）**：若 $S(x) < T_{healthy}$，打上“健康（Label=0）”的**伪标签**。
   - **高置信度异常（High-Confidence Anomaly）**：若 $S(x) > T_{anomaly}$，打上“异常（Label=1）”的**伪标签**。
     - *注意*：对于异常样本，我们还可以利用 **ReLU Residuals** [1] 进行像素级归因。计算 $R = \text{ReLU}(X - \hat{X})$。如果残差主要集中在100Hz处，可标记为“主磁通异常”；若集中在高频，标记为“放电/撞击”。这为细粒度伪标签提供了可能。
   - **不确定区域（Uncertain）**：若 $T_{healthy} \le S(x) \le T_{anomaly}$，该样本处于模糊地带，**不赋予伪标签**，或提交人工专家审核。
3. 数据集扩充（Data Expansion）：
   将生成了伪标签的样本加入到训练池中。
   - 健康伪标签样本：继续用于VAE的无监督重构训练，巩固模型对正常分布的记忆。
   - 异常伪标签样本：由于VAE是仅在健康数据上训练的，异常样本不应直接用于训练VAE（否则VAE学会了重构故障，就无法检测故障了）。
   - **策略调整**：利用这些异常伪标签，我们可以训练一个**并行的二分类器（如ResNet-Classifier）**。
4. **协同训练（Co-training）**：
   - **模型A（VAE）**：继续在扩充后的健康数据集上微调，追求更极致的正常样本重构，压低 $T_{healthy}$。
   - **模型B（Classifier）**：利用VAE筛选出的“确信异常”和“确信健康”样本进行有监督训练。
   - **集成决策**：最终部署时，同时参考VAE的重构误差和Classifier的分类概率，进一步提高鲁棒性。

---

6. 代码实现方案的关键技术细节

为了确保方案的可落地性，以下列出代码实现层面的关键技术参数与库选择。

6.1 技术栈推荐

- **深度学习框架**：PyTorch (因其动态图特性，方便调试自定义的VAE Loss和ResNet修改)。
- **小波变换库**：PyWavelets (pywt) 或 scipy.signal.cwt。推荐使用 GPU 加速的实现（如 pytorch_wavelets），因为CWT计算量较大。
- **数据处理**：Pandas (处理元数据/工况)，NumPy。

6.2 核心类结构设计

建议代码工程包含以下三个核心类：

6.2.1 DataConverter (Zerone逻辑实现)

Python

```python
class DataConverter:
    def __init__(self, config):
        self.cwt_scales = np.arange(1, 129)
        self.feature_extractor = TimeDomainFeatures() # T1-T13

    def transform(self, raw_signal, context_dict):
        # 1. CWT变换 -> (256, 256) 图像
        cwt_img = self.apply_cwt(raw_signal)

        # 2. 机理特征计算 -> Vector
```

```
        mech_vec = self.feature_extractor(raw_signal)
        # 归一化并Tile成 (256, 256)
        mech_layer = self.vector_to_grid(mech_vec)

        # 3. 上下文嵌入 -> Vector
        # 将型号、位置映射为归一化数值
        ctx_vec = self.encode_context(context_dict)
        ctx_layer = self.vector_to_grid(ctx_vec)

        # 4. 合并为三通道张量
        return np.stack([cwt_img, mech_layer, ctx_layer], axis=0)
```

6.2.2 SpatialVAE (模型定义)

Python

```
class SpatialVAE(nn.Module):
    def __init__(self):
        super().__init__()
        # Encoder: 基于ResNet18，去掉最后几层
        self.encoder = ResNet18_Backbone(in_channels=3)
        # 空间隐变量卷积层
        self.mu_conv = nn.Conv2d(512, 64, kernel_size=1)
        self.logvar_conv = nn.Conv2d(512, 64, kernel_size=1)
        # Decoder: 镜像结构
        self.decoder = ResNet_Decoder_Block()

    def reparameterize(self, mu, logvar):
        std = torch.exp(0.5 * logvar)
        eps = torch.randn_like(std)
        return mu + eps * std

    def forward(self, x):
        features = self.encoder(x)
        mu = self.mu_conv(features)
        logvar = self.logvar_conv(features)
```

```
        z = self.reparameterize(mu, logvar)
        recon = self.decoder(z)
        return recon, mu, logvar
```

6.2.3 PseudoLabeler (流程控制)

该类负责加载训练好的VAE，对新数据流进行Batch推理，根据设定的分位数阈值（Quantile Thresholds）输出带有伪标签的数据列表，并触发重训练（Retraining）信号。

---

7. 实验验证与预期性能指标

7.1 验证策略

由于缺乏真实的故障全集，验证应采用**合成故障注入（Synthetic Fault Injection）**与少量真实案例结合的方式。
参考1的方法，我们可以人工合成以下故障样本用于测试模型敏感度：

1. **频谱漂移**：人工修改信号，增加非谐波分量（模拟部件松动）。
2. **幅值调制**：对原始信号乘以低频正弦包络（模拟转子/部件偏心）。
3. **瞬态注入**：叠加衰减的脉冲信号（模拟局部放电）。

7.2 评价指标

- **AUROC (Area Under ROC Curve)**：评估异常评分 $S(x)$ 将正常与故障样本分离的能力，不依赖具体阈值。
- **重构保真度 (PSNR/SSIM)**：评估模型对健康样本的压缩还原能力。健康样本的SSIM应极高（>0.95），而合成故障样本的SSIM应显著降低。
- **潜空间可视化 (t-SNE)**：将隐变量 z 降维可视化。理想情况下，不同型号的变压器在隐空间应呈现为紧凑但可分的簇（Cluster），而故障样本应游离于这些簇之外[1]。

---

8. 结论

本报告提出了一套针对异构交流变压器振动数据的深度无监督监测方案。该方案的创新性与优势总结如下：

1. **异构性的机理化解**：通过借鉴并改进**Zerone**逻辑，将离散的设备上下文与连续的振动特征融合到同一张图像中，使得单一模型能够同时监控多型号、多测点的设备，无需为每台变压器单独建模，极大地降低了部署成本。
2. **感知的深度化**：采用**CWT-ResNet-VAE**架构，利用连续小波变换的多分辨率特性和残差网络的深层特征提取能力，配合空间隐空间设计，最大程度保留了故障的早期微弱征兆。
3. **闭环的演进能力**：设计的伪标签扩充流程，使得系统不再是一个静态的检测器，而是一个能够利用海量监测数据不断自我进化、自我确认边界的智能系统。

该方案在理论上自洽，充分利用了提供的研究素材，并针对变压器物理特性进行了针对性优化，是一套具备高度落地可行性的工业AI解决方案。

参考文献索引

- [1] Radicioni, L., et al. (2025). Vibration-Based Anomaly Detection in Industrial Machines: A Comparison of Autoencoders and Latent Spaces. *Machines*.
- [1] Komorska, I., & Puchalski, A. (2024). Condition Monitoring Using a Latent Space of Variational Autoencoder Trained Only on a Healthy Machine. *Sensors*.
- [1] Song, Y., et al. (2024). Unsupervised anomaly detection in shearers via autoencoder networks and multi-scale correlation matrix reconstruction. *International Journal of Coal Science & Technology*.
- [1] Kim, Y., & Yoon, H. (2025). Integrating vibration signal analysis and image embedding for enhanced bearing fault diagnosis in manufacturing. *Scientific Reports*.

引用的著作

1. Kim和Yoon - 2025 - Integrating vibration signal analysis and image embedding for enhanced bearing fault diagnosis in ma.pdf